

Entregable 3: Matriz de Optimización de Costos

Criterio de decisión: un modelo/estrategia distinto por tipo de tarea

El sistema no usa un único modelo de IA para todo — cada tarea se asigna al recurso más barato que la resuelve bien, siguiendo el principio de que las tareas mecánicas no necesitan el mismo poder de cómputo que las tareas de calidad/creatividad.

Tarea	Recurso usado	Por qué este y no otro	Costo relativo
Extracción de datos del mail (nombre, email, descripción, clasificación de urgencia)	Gemini Flash	Es una tarea de lectura y estructuración simple, de baja ambigüedad. No requiere razonamiento profundo ni redacción de calidad — un modelo rápido y económico la resuelve igual de bien que uno costoso. Se ejecuta por cada mail que llega , así que el ahorro por llamada se multiplica por volumen.	Bajo (modelo “mini”/Flash)
Redacción de la propuesta comercial (Urgencia Alta)	Gemini Pro	Es la tarea de mayor valor agregado del sistema: necesita seguir un manual de tono complejo, generar texto persuasivo y coherente, y aplicar reglas de anti-alucinación con criterio. Se ejecuta solo para el subconjunto de casos que requieren respuesta inmediata (Alta), no para todo el volumen.	Medio-Alto (modelo “Pro”, pero volumen acotado)
Redacción de la propuesta comercial (Urgencia Media/Baja)	Gemini Pro, diferido con Wait	Mismo modelo y misma calidad que la rama Alta (reutiliza la misma cadena de nodos), pero la ejecución se pospone a un horario de baja demanda en vez de procesarse al instante. No genera descuento de precio por token, pero sí evita picos de concurrencia y prioriza recursos hacia los casos urgentes.	Medio (mismo costo por llamada, pero mejor distribución en el tiempo)

Por qué la clasificación de urgencia es la palanca de ahorro, no la complejidad del pedido

En una iteración anterior del diseño se consideró clasificar por “complejidad del pedido” para elegir el modelo. Se descartó: la complejidad de un pedido no determina si puede esperar 24hs una respuesta, mientras que la urgencia declarada por el cliente sí lo determina directamente. Atar el ahorro de costos a la urgencia real del negocio es un criterio más defendible y más simple de auditar que estimar “complejidad” con otro llamado a IA (lo cual además agregaría costo, no lo reduciría).

Estado de implementación y próximos pasos

Por restricciones de tiempo, la versión entregada implementa la diferenciación Alta vs. Media/Baja mediante un **nodo Wait** (pospone el procesamiento a horario de baja demanda) en vez de la Batch API real de Gemini. Esto logra el objetivo de *priorización* (no saturar el sistema, atender primero lo urgente) pero **no genera el ahorro de precio por token** que sí ofrecería la Batch API.

Próxima iteración (diseño ya definido, pendiente de implementación): reemplazar el nodo Wait por el flujo de Batch API descrito en el Entregable 1 (envío agrupado de múltiples propuestas + recolección asincrónica de resultados vía `metadata.key`), lo cual sí generaría el ahorro estimado a continuación.

Urgencia	% estimado del volumen	Estrategia implementada	Estrategia prevista (futura)
Alta	~30%	Tiempo real, Gemini Pro	Sin cambios
Media/Baja	~70%	Gemini Pro diferido (Wait) — mismo costo por token	Batch API — descuento por lote sobre ese 70% del volumen

El 100% de las propuestas ya pasan primero por Gemini Flash para extracción — un modelo notablemente más económico que usar Gemini Pro también para esa etapa, generando ahorro real sobre el 100% del volumen, independientemente del estado de la rama Media/Baja.

Control de tokens

Ambos nodos de IA limitan explícitamente el `Max Output Tokens` según la tarea: ~200 tokens para la extracción (una respuesta JSON corta y acotada) y ~1200-1500 tokens para la redacción (una propuesta comercial completa). Esto evita pagar por generación innecesaria en la tarea que no la requiere.

Estimación cuantitativa de costos

Precios oficiales de la API de Gemini vigentes a septiembre 2026 (Google AI, tarifa estándar por millón de tokens):

Modelo	Entrada (por MTok)	Salida (por MTok)
Gemini 3.6 Flash (extracción)	\$1.50	\$7.50
Gemini 3.1 Pro (redacción)	\$2.00	\$12.00
Batch API (cualquiera de los dos)	50% de descuento sobre entrada y salida	50% de descuento sobre entrada y salida

Supuestos de tokens por llamada (estimación ilustrativa)

Concepto	Extracción (Flash)	Redacción (Pro)
Prompt de sistema (fijo)	~300 tokens	~1.200 tokens (manual de tono completo)
Contenido variable (mail / descripción)	~400 tokens	~400 tokens
Salida	~100 tokens (JSON)	~600 tokens (propuesta completa)

Proyección mensual (volumen ilustrativo: 500 propuestas/mes, 30% Alta / 70% Media-Baja)

Escenario	Entrada	Salida	Total
Extracción (500 llamadas, Flash, todas)	$500 \times 700 = 350.000 \text{ tok} \rightarrow 0,35 \times \$1,50 = \$0,53$	$500 \times 100 = 50.000 \text{ tok} \rightarrow 0,05 \times \$7,50 = \$0,38$	\$0,90
Redacción Alta (150 llamadas, Pro, tiempo real)	$150 \times 1.600 = 240.000 \text{ tok} \rightarrow 0,24 \times \$2 = \$0,48$	$150 \times 600 = 90.000 \text{ tok} \rightarrow 0,09 \times \$12 = \$1,08$	\$1,56
Redacción Media/Baja — implementado (Wait, sin descuento) (350 llamadas, Pro, tarifa estándar)	$350 \times 1.600 = 560.000 \text{ tok} \rightarrow 0,56 \times \$2 = \$1,12$	$350 \times 600 = 210.000 \text{ tok} \rightarrow 0,21 \times \$12 = \$2,52$	\$3,64
Total mensual actual (Wait)			\$6,10
Redacción Media/Baja — con Batch API real (350 llamadas, 50% off)	$350 \times 1.600 = 560.000 \text{ tok} \rightarrow 0,56 \times \$1 = \$0,56$	$350 \times 600 = 210.000 \text{ tok} \rightarrow 0,21 \times \$6 = \$1,26$	\$1,82
Total mensual proyectado (con Batch API real)			\$4,28

Ahorro potencial no capturado en la versión actual: $\$6,10 - \$4,28 = \$1,82/\text{mes}$ ($\approx 30\%$ del costo total de IA, y $\approx 50\%$ específicamente sobre el costo de redacción de las propuestas Media/Baja) — este es el ahorro que se obtendría al reemplazar el nodo Wait por la Batch API real descrita en el Entregable 1.

Nota: cifras basadas en precios oficiales de Google AI vigentes a septiembre 2026 y en supuestos de volumen/tokens ilustrativos, no en datos de producción reales. Sirven para dimensionar el orden de magnitud del ahorro, no como facturación exacta.

